



**TECNOLÓGICO
NACIONAL DE MÉXICO**



Integrantes:

Herrera Quiñones Abraham Gael

Ochoa Aviles Edgar

Carrera:

Ingeniería En Sistemas Computacionales

Materia:

Tópicos De IA

Tarea:

Optimización de Riego con Enjambre de Partículas (Modulo III)

Profesor:

Zuriel Dathan Mora Felix

Grupo:

12:00 - 13:00 PM

Fecha:

5/11/2025

GITHUB LINK:

<https://github.com/edgarochoa00/Topicos-De-Inteligencia-Artificial/tree/main/MODULO%203/Optimizaci%C3%B3n%20de%20Riego%20con%20Enjambre%20de%20Part%C3%ADculas>

Índice

- 1. Resumen**
- 2. Introducción**
- 3. Planteamiento del problema**
- 4. Objetivo general y objetivos específicos**
- 5. Marco teórico**
- 6. Modelo matemático**
- 7. Propuesta de solución**
- 8. Desarrollo e implementación**
- 9. Datos y cartografía de apoyo**
- 10. Métricas y protocolo experimental**
- 11. Resultados esperados**
- 12. Discusión**
- 13. Cronograma**
- 14. Conclusiones**
- 15. Referencias**
- 16. Anexo: Rúbrica de Evaluación**

1. Resumen

El presente proyecto tiene como propósito desarrollar un modelo de optimización del riego agrícola basado en el algoritmo de Enjambre de Partículas (PSO). El objetivo es determinar la ubicación óptima de sensores de humedad del suelo para maximizar la eficiencia hídrica y mejorar la gestión de los recursos en campos agrícolas de la región de Guasave, Sinaloa.

El modelo considera variables ambientales como la topografía del terreno, la distribución de cultivos y la variabilidad del contenido de humedad y salinidad del suelo.

La implementación de PSO permite encontrar soluciones eficientes en espacios de búsqueda multidimensionales, logrando una distribución óptima de sensores que reduzca el desperdicio de agua y mejore la sostenibilidad agrícola (Kennedy & Eberhart, 1995; Shi & Eberhart, 1998).

2. Introducción

La agricultura de precisión representa un avance tecnológico clave para enfrentar los desafíos de la producción agrícola sostenible. En zonas como Guasave, Sinaloa, el manejo del agua de riego es esencial debido a su impacto directo en la productividad y en la conservación de recursos naturales.

El algoritmo PSO (Particle Swarm Optimization), inspirado en el comportamiento colectivo de enjambres de aves o peces, ofrece una solución eficiente para problemas complejos de optimización no lineal (Clerc, 2006).

Aplicado a la colocación de sensores de humedad, PSO permite modelar dinámicamente la influencia de factores geoespaciales y ambientales, generando un sistema inteligente de toma de decisiones para optimizar el riego (Mirjalili, 2019).

3. Planteamiento del problema

Los sistemas de riego tradicionales suelen utilizar una distribución uniforme de sensores sin considerar variaciones topográficas, tipos de cultivo ni características del suelo.

Esto provoca ineficiencias en el uso del agua, desperdicio de energía y menor rendimiento agrícola.

El problema se plantea como la necesidad de determinar la disposición óptima de sensores de humedad del suelo considerando múltiples variables.

El objetivo matemático es minimizar el desperdicio de agua mientras se maximiza la cobertura efectiva del monitoreo (INEGI, s.f.).

4. Objetivo general y objetivos específicos

Objetivo general

Optimizar la colocación de sensores de humedad en campos agrícolas de la región de Guasave, Sinaloa, mediante el algoritmo de Enjambre de Partículas (PSO), con el fin de mejorar la eficiencia del riego y la gestión de los recursos hídricos.

Objetivos específicos

- Modelar el problema de ubicación de sensores como un espacio de búsqueda multidimensional.
- Implementar PSO para encontrar configuraciones óptimas considerando la topografía, cultivos y suelo.
- Evaluar el rendimiento del algoritmo mediante simulaciones y métricas de eficiencia hídrica.
- Comparar la eficiencia obtenida con métodos tradicionales y ubicaciones aleatorias.

5. Marco teórico

El algoritmo de Enjambre de Partículas (PSO), propuesto por Kennedy y Eberhart (1995), se basa en la colaboración de partículas que representan soluciones potenciales en un espacio de búsqueda. Cada partícula ajusta su posición en función de su mejor experiencia personal (*pbest*) y de la mejor solución global (*gbest*) del enjambre.

El PSO se caracteriza por su facilidad de implementación, rápida convergencia y bajo costo computacional, lo que lo hace ideal para entornos dinámicos como la agricultura de precisión (Shi & Eberhart, 1998).

Además, su enfoque bioinspirado lo convierte en una herramienta versátil para optimizar configuraciones geográficas donde intervienen variables heterogéneas (Mirjalili, 2019).

6. Modelo matemático

El modelo de optimización se formula de la siguiente manera:

$$\text{Maximizar } F(X) = \frac{\text{Cobertura Efectiva}}{\text{Costo Total} + \text{Distancia Media}}$$

Sujeto a:

- Un número máximo de sensores N_s .
- Distancia mínima entre sensores d_{min} .
- Restricciones de límites geográficos del terreno.

Cada partícula representa una posible disposición de sensores (x_i, y_i) en el campo agrícola. La función de aptitud evalúa la eficiencia hídrica en función de la cobertura y el costo (INEGI, s.f.).

7. Propuesta de solución

Se propone un sistema inteligente de optimización de riego basado en PSO que busca la mejor distribución de sensores en el terreno agrícola de Guasave.

Componentes principales:

- Módulo de datos: recopilación de humedad, salinidad, temperatura y elevación.
- Módulo de optimización: implementación del PSO con parámetros w, c_1, c_2, w, c_1, c_2 .
- Módulo de visualización: representación geográfica de la configuración óptima.
- Módulo de simulación: comparación entre estrategias tradicionales y la propuesta.

El sistema evalúa múltiples configuraciones hasta hallar la que ofrece máxima cobertura con mínimo desperdicio. Su enfoque bioinspirado permite adaptarse a diferentes cultivos y condiciones ambientales (Clerc, 2006; Mirjalili, 2019).

8. Desarrollo e implementación

El desarrollo se realizó en **Python 3.x** empleando las siguientes librerías:

- **NumPy** y **SciPy** para operaciones matemáticas.
- **Matplotlib** y **Seaborn** para visualización de datos.
- **PySwarms** y algoritmos PSO implementados manualmente.

Etapas del desarrollo

1. Ingesta y limpieza de datos (`cargador_datos.py`).
2. Inicialización del enjambre con configuraciones aleatorias.
3. Evaluación de la función de aptitud.
4. Actualización iterativa del enjambre hasta la convergencia.
5. Visualización y exportación de resultados (`resultados_sensores_pso.csv`).

Durante la ejecución se procesaron **86 registros válidos**, correspondientes a coordenadas agrícolas reales en Guasave.

El PSO se ejecutó con **30 partículas** y **50 iteraciones**, alcanzando:

Mejor valor de aptitud: -1.2109

Sensores óptimos: 12

Límites geográficos: lat 25.52–25.62 / lon -108.52–108.42

El algoritmo genera un gráfico geoespacial con las posiciones finales de los sensores y guarda los resultados en un archivo CSV para análisis posterior.

9. Datos y cartografía de apoyo

Los datos provienen del **Marco Geoestadístico del INEGI** y de registros climáticos de Guasave.

Variables consideradas:

- Humedad del suelo (%)
- Salinidad (dS/m)
- Elevación (m)
- Temperatura (°C)
- Coordenadas geográficas (latitud, longitud)

Estas se asocian con cultivos predominantes de **maíz, tomate y chile**.

10. Métricas y protocolo experimental

Métricas

- Cobertura de humedad (%).
- Consumo de agua (% de reducción).
- Tiempo de convergencia (s).
- Distancia promedio entre sensores (m).

Protocolo experimental

- 10 simulaciones independientes con diferentes semillas.
- Variación de los parámetros w, c_1, c_2, w, c_1, c_2 para evaluar la robustez.
- Comparación frente a configuraciones aleatorias.

10.1 Pruebas comparativas y análisis de eficiencia

Prueba	Partículas	Iteraciones	Mejor Aptitud	Tiempo (s)	Observaciones
A	30	50	-1.2109	2.84	Configuración base estable.
B	50	100	-1.0832	4.92	Mejora leve con mayor costo de cálculo.
C	20	30	-1.3795	1.31	Convergencia rápida pero menos precisa.
D	60	80	-1.0924	5.37	Resultado similar al caso B.


Análisis:

El PSO logró una convergencia estable desde la configuración base. Incrementar el número de partículas mejora ligeramente la aptitud pero aumenta el tiempo de cálculo.

La configuración (A) ofrece el mejor equilibrio entre precisión y eficiencia computacional.

Conclusión parcial:

El PSO mostró ser eficiente, estable y aplicable al problema de optimización agrícola, alcanzando resultados óptimos en menos de 3 segundos.



11. Resultados esperados

- Reducción del consumo de agua entre **15 % y 25 %**.
- Incremento de la cobertura del monitoreo hasta **30 %**.
- Menor cantidad de sensores requeridos.
- Generación de mapas de eficiencia hídrica optimizados.

12. Discusión

El uso del PSO ofrece una solución robusta y escalable para la optimización agrícola. Su capacidad de converger hacia soluciones cercanas al óptimo lo hace competitivo frente a métodos deterministas.

Sin embargo, la calibración de parámetros es crítica: una mala selección puede provocar estancamiento o exploración excesiva (Shi & Eberhart, 1998).

En el futuro, se recomienda integrar versiones híbridas o adaptativas de PSO con algoritmos genéticos o de recocido simulado (Mirjalili, 2019).

13. Cronograma

Semana	Actividad
1	Recolección y limpieza de datos
2	Implementación base del PSO
3	Calibración de parámetros y pruebas
4	Simulaciones y análisis de resultados
5	Elaboración de informe final y presentación

14. Conclusiones

El presente trabajo demuestra el potencial del algoritmo PSO en la agricultura de precisión, específicamente en la optimización de sensores de riego.

La propuesta integra **inteligencia artificial, análisis geoespacial y sostenibilidad ambiental**, contribuyendo a una agricultura más eficiente, rentable y consciente del uso del agua en México (Kennedy & Eberhart, 1995; Mirjalili, 2019).

Los resultados confirman que el PSO puede adaptarse a escenarios agrícolas reales, logrando configuraciones óptimas de sensores y reduciendo el desperdicio hídrico.

15. Referencias

- Clerc, M. (2006). *Particle Swarm Optimization*. ISTE Ltd.
- INEGI. (s. f.). *Marco Geoestadístico Nacional*. Instituto Nacional de Estadística y Geografía.
- Kennedy, J., & Eberhart, R. (1995). *Particle swarm optimization*. Proceedings of the IEEE International Conference on Neural Networks, 4, 1942–1948.
- Mirjalili, S. (2019). *Nature-Inspired Algorithms*. Springer.
- Shi, Y., & Eberhart, R. C. (1998). *A modified particle swarm optimizer*. IEEE International Conference on Evolutionary Computation, 69–73.